

CAKE DIGITAL BANK

LLM Knowledge Base Framework

Tiếp cận theo mô hình LLM-as-an-Operating-System của Andrej Karpathy

Đạm Hồ

dam.ho@cake.vn · 11 May 2026 · v1.0

Bài toán Cake đang gặp

01

Tribal knowledge

Kiến thức nằm trong đầu engineer senior.
Một người nghỉ — task ngưng.

02

Search ngu

Confluence search trả về rác. Engineer hỏi đồng nghiệp thay vì tìm.

03

Onboarding chậm

Engineer mới mất 2-4 tuần để hiểu hệ thống.

04

Trùng lặp tài liệu

Cùng một quy trình mô tả ở 3 nơi, không đồng bộ.

05

Support lặp lại

CS agent trả lời cùng một câu hỏi 50 lần/ngày.

06

Compliance phân tán

Quy định SBV, AML, KYC nằm rải rác, khó audit.

Karpathy: LLM là CPU của một OS mới

Nov 2023 · 'Intro to Large Language Models' — góc nhìn thay đổi cách thiết kế hệ thống AI



LLM is the kernel of a new emerging operating system.

Context window là RAM. Vector DB là disk. Tool là I/O. Multi-agent là multi-threading.

— A. Karpathy

Vì sao điều này quan trọng cho KB?

1 Không phải database

KB là persistent storage cho một CPU mới biết đọc-hiểu tiếng người.

2 Phân tầng bộ nhớ

Hot/warm/cold giống RAM-Disk, không phải mọi thứ ngang nhau.

3 Paging logic

Quyết định cái gì 'paged-in' vào context cho từng task.

4 Tools là phần của KB

Không chỉ đọc — viết, hành động, feedback ngược lại.

OS truyền thống ↔ LLM OS

OS truyền thống	LLM OS	Tech ví dụ
CPU / kernel	LLM (reasoning core)	Claude, GPT, Gemini, Llama
RAM	Context window	128k-1M token, đắt, dễ tràn
Disk / Filesystem	Vector DB + tài liệu	pgvector, Qdrant, Pinecone, S3
I/O peripherals	Tools / function calling	Browser, code exec, internal API
Process scheduler	Agent orchestration	LangGraph, custom
Multi-thread	Multi-agent	Specialist + supervisor
Network	MCP / inter-agent	Model Context Protocol

Kiến trúc tham chiếu — 5 lớp

Đọc từ dưới lên theo logic OS — Layer 1 bền vững, Layer 5 linh hoạt

LLM OS Knowledge Base — kiến trúc 5 lớp

Theo framework "LLM as an Operating System" (Karpathy, 2023) · áp dụng cho Cake Digital Bank

LAYER 5 · KERNEL

Orchestration

Routing · Multi-agent · Quality control · Observability · Governance

LAYER 4 · PERIPHERALS

Tools & Actions

Jira / Slack / Confluence / Internal APIs · Web search · Code exec · Multi-modal I/O

LAYER 3 · RAM / MEMORY MANAGER

Context Assembly

Query rewriting · Retrieval orchestration · Compression · Memory tiers (session/long-term)

LAYER 2 · FILESYSTEM

Indexing & Retrieval

Hybrid search (BM25 + dense) · Re-ranking · Knowledge graph · Metadata filters

LAYER 1 · DISK

Storage

Raw docs · Vector embeddings · Structured (Postgres) · Object storage · Audit & version

Sources: Confluence · Jira · GitHub · Slack · Box · Customer tickets · Regulatory docs

CAKE BRAND THEME · Pink-500 · Grape-500 · Grape-900 · Mint-500 · Amber-500
Layer càng thấp → bền vững & chậm thay đổi. Layer càng cao → linh hoạt & product-specific.



CPU / KERNEL

Reasoning core



CONTEXT

128k-1M tokens

HOT MEMORY

Session cache

WARM

Vector DB

COLD

Object storage

Memory hierarchy
RAM → Disk

Storage

the Disk

Mục tiêu

Lưu trữ bền vững mọi tài sản tri thức của tổ chức

Raw content

Markdown, PDF, DOCX, code, transcript, ticket — object storage (S3/MinIO)

Vector store

Embedding chunks — PostgreSQL + pgvector (khuyến nghị Cake)

Structured

Metadata, taxonomy, relationships — Postgres relational + GraphQL

Audit / version

Git-like: mọi thay đổi có version + diff + author + timestamp

Nguyên tắc · Content-addressable · Single source of truth · Tiered hot/warm/cold

Indexing & Retrieval

the Filesystem

Mục tiêu

Trả lời: tài liệu nào liên quan đến query này — nhanh và chính xác

BM25 (keyword)

Bắt mã giao dịch, account number, error code — thứ vector miss

Dense (embedding)

Bắt paraphrase, ngữ nghĩa — Voyage/OpenAI cho tiếng Việt

Metadata filter

Team, sensitivity, recency, source — không leak cross-team

Re-ranking

Cross-encoder top-50 → top-5, tăng accuracy 10-20%

Nguyên tắc · Hybrid > pure dense · Re-rank trước khi pack vào context

Context Assembly

RAM / Memory Manager

Mục tiêu

Chọn đúng nội dung từ Layer 2 để 'paging' vào context cho từng task

Query understanding

Rewrite, expand acronym, detect intent

Retrieval orchestration

Chạy song song nhiều retriever, merge kết quả

Compression

Tóm tắt tài liệu dài, loại bỏ phần không liên quan — tiết kiệm 60–80% token

Memory tiers

Ephemeral (turn) · session · long-term (ghi ngược vào KB)

Nguyên tắc · Đây là tầng tách 'KB tốt' với 'AI assistant tốt'

Mục tiêu

Cho LLM khả năng làm hành động thật — phân biệt 'chatbot' với 'agent'

Read tools

Search Confluence, query Jira, đọc PR, query data warehouse

Write tools

Tạo PR/branch, mở Jira, post Slack, update Confluence — có approval gate

Compute tools

Code interpreter, SQL exec, calculator

MCP protocol

Chuẩn của Anthropic — đầu tư MCP server cho Cake Core, FCC, T24

Nguyên tắc · Write tools BẮT BUỘC có approval gate · Audit log mọi action

Orchestration

Kernel

Mục tiêu

Điều phối, đảm bảo quality, security, observability

Routing

Engineering query → agent eng; compliance → agent compliance + reviewer

Multi-step reasoning

Task phức tạp phân rã thành steps, mỗi step có thể call tool

Quality control

Groundedness check, block khi confidence thấp, force citation

Observability + Governance

Trace mọi turn · PII redaction · RBAC · audit cho compliance

Nguyên tắc · Không có Layer 5 = không phải production — chỉ là demo

3 use case ưu tiên trong 6 tháng đầu

USE CASE #1

Engineering Copilot

Onboard service, đọc runbook, query incident history, gợi ý fix bug

Users

Senior eng, SRE, Platform team

Sources

GitHub · Confluence · Jira

Impact

Tiết kiệm 4–8h/tuần/eng

USE CASE #2

Internal Support Bot

Trả lời câu hỏi quy trình nội bộ — HR, IT, finance, compliance

Users

Toàn nhân viên

Sources

Confluence · ServiceNow

Impact

Giảm 60% ticket lặp

USE CASE #3

Customer Support Assistant

Hỗ trợ CS agent: card, transaction, KYC, loan — không trả lời thẳng khách

Users

CS Tier 1–2

Sources

FAQ · product docs · transaction API

Impact

Giảm AHT 30%, tăng FCR 20%

Stack đề xuất cho Cake

Self-host core nội bộ (L1-3) + frontier LLM cho reasoning + OSS cho agent layer

Layer	Lựa chọn	Lý do
LLM	Claude Sonnet 4.6 + Haiku 4.5	Reasoning cao, context dài, agentic mạnh
Embedding	Voyage AI multilingual hoặc OpenAI 3-large	Hỗ trợ tiếng Việt tốt
Vector DB	PostgreSQL + pgvector	Đã có Postgres nội bộ, tránh vendor lock-in
Object store	MinIO (on-prem) hoặc S3	Tài liệu thô + version
Search	OpenSearch (BM25) + pgvector (dense)	Hybrid; self-host được
Re-ranker	Cohere Rerank v3 hoặc local cross-encoder	Tăng accuracy 10-20%
Agent fw	LangGraph hoặc Pydantic AI	Production-grade, observable
Tool protocol	MCP (Model Context Protocol)	Chuẩn Anthropic, tái sử dụng
Observability	Langfuse (self-host)	Trace, eval, prompt versioning
Auth	Tích hợp SSO Cake (Keycloak/Okta)	Reuse identity

12 tháng — 3 phase từ baseline đến LLM OS

Roadmap triển khai 12 tháng

3 giai đoạn — từ RAG baseline đến LLM OS hoàn chỉnh



Sau mỗi phase: review eval, prune & re-prioritize. Không nhảy phase trước khi KPI phase trước đạt mức.

Top rủi ro & cách giảm thiểu

CAO

Data leak qua LLM cloud

PII redaction + self-host cho sensitive + audit log

CAO

Hallucination với citation giả

Citation enforcement + grounded eval + confidence threshold

CAO

KB chất lượng thấp do source xấu

Curation pipeline + author scoring + 'mark as outdated' UX

TB

Cost LLM tăng không kiểm soát

Caching + cheaper model routing + budget alert

TB

Vendor lock-in

Abstract layer, swap-able provider, eval on-going

NEXT STEPS

4 tuần tới

01

Align leadership

Họp chốt use case ưu tiên cho Phase 1 (Engineering Copilot khuyến nghị)

02

Build POC

Postgres + pgvector + Claude + 1 connector (Confluence) — 2 tuần

03

Golden set

Xây 50 câu hỏi test + eval baseline để đo trước-sau

04

Demo + propose

Trình demo + đề xuất Phase 1 budget + team (1 senior + 1 mid)